

Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №1-2
По дисциплине: «Математическая статистика»
Тема: «Гистограммы и плотности распределений»

Выполнила студент: Киселева Ксения
учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург
2026

Оглавление

1. Постановка задачи.....	3
2. Теоретическая часть	3
3. Реализация	4
4. Результаты	5
5. Обсуждение.....	7
6. Выводы	9

1. Постановка задачи

Цель работы: изучение основных методов описательной статистики: визуализация распределений, вычисление характеристик положения и рассеяния, анализ влияния объема выборки и выбросов на оценки параметров.

Задачи:

- Сгенерировать выборки различного объема ($n = 10, 100, 1000$) для пяти законов распределения: нормального, Коши, Лапласа, Пуассона и равномерного.
- Построить гистограммы полученных выборок, наложив на них графики теоретических плотностей вероятности.
- Проанализировать влияние размера выборки и количества интервалов гистограммы на визуальное восприятие распределения.
- Для тех же выборок вычислить выборочные характеристики положения: среднее арифметическое, медиану, полусумму экстремумов, полусумму квартилей и усеченное среднее.
- Провести множественные эксперименты (1000 повторений) для оценки математического ожидания и дисперсии каждой характеристики.
- Сравнить полученные оценки с теоретическими значениями и сделать выводы о состоятельности и робастности (устойчивости к выбросам) рассмотренных статистик.

2. Теоретическая часть

В работе исследуются пять законов распределения. Для непрерывных распределений (нормальное, Коши, Лапласа, равномерное) используется плотность вероятности $f(x)$, для дискретного (Пуассона) — функция вероятности $P(k)$.

1) Нормальное $N(x; 0, 1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}; x \in \mathbb{R}$ (1)

2) Коши $C(x; 0, 1); f(x) = \frac{1}{\pi(1+x^2)}; x \in \mathbb{R}$ (2)

3) Лапласа $L(x; 0, \frac{1}{\sqrt{2}}); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}; x \in \mathbb{R}$ (3)

4) Пуассона $P(k; 5); f(k) = \frac{5^k e^{-5}}{k!}; k = 0, 1, 2 \dots$ (4)

5) Равномерное $U(x; -\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases}$ (5)

Для каждой сгенерированной выборки $\{x_1, x_2, \dots, x_n\}$ вычислялись следующие статистики:

1) Выборочное среднее $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$

- 2) Выборочная медиана $med = x_{\frac{n+1}{2}}$ – значение элемента, стоящего в середине вариационного ряда.
- 3) Полусумма экстремальных элементов $z_R = \frac{x_{min} + x_{max}}{2}$
- 4) Полусумма квартилей $z_R = \frac{z_{1/4} + z_{3/4}}{2}$
- 5) Усечённое среднее $z_{tr} = \frac{1}{n-2k} \sum_{i=k+1}^{n-k} x_i$; $k = [0.1n]$ (с отбрасыванием 10% наименьших и наибольших значений)

Для каждой характеристики находятся среднее и дисперсия:

$$E(z) = \bar{z} = \frac{1}{1000} \sum_{j=1}^{1000} z_j ; D(z) = \overline{z^2} - \bar{z}^2$$

3. Реализация

Язык программирования: Python 3.10

Среда разработки: Jupyter Notebook

Библиотеки:

- a. numpy - для генерации случайных чисел и матричных вычислений.
- b. scipy.stats - для работы с теоретическими плотностями распределения и квартилями.
- c. matplotlib.pyplot для построения гистограмм и графиков.

Краткое описание методов:

- optimal_bins(data_vector) определяет оптимальное число интервалов гистограммы по правилу Фридмана-Диакониса, возвращает целое число биннов для группировки данных.
- theoretical_curve(dist_type, x_range) вычисляет значения теоретической плотности вероятности для заданного распределения (gauss, cauchy, laplace, uniform) в точках x_range, возвращает массив плотностей.
- calculate_all_stats(sample_array) вычисляет пять характеристик положения для одной выборки: среднее, медиану, полусумму экстремумов, полусумму квартилей и усечённое среднее, возвращает словарь с результатами.
- print_table(dist_name, data_dict) формирует и выводит в консоль отформатированную таблицу с результатами вычислений для всех объёмов выборки.
- generate_samples_and_plot() генерирует выборки для всех пяти распределений и трёх объёмов (10, 100, 1000), строит гистограммы с наложенными теоретическими кривыми.
- run_multiple_experiments() проводит множественные эксперименты (1000 повторений) для оценки математического ожидания и дисперсии каждой характеристики положения.

4. Результаты




Рисунок 1: Гистограммы для нормального распределения

Нормальное $N(0,1)$

Статистика	$n=10$	$n=100$	$n=1000$
Среднее	0.0 ± 0.3	0.0 ± 0.1	-0.0 ± 0.0
Медиана	0.0 ± 0.4	0.0 ± 0.1	-0.0 ± 0.0
Z_R	-0.0 ± 0.4	0.0 ± 0.3	0.0 ± 0.3
Z_Q	0.0 ± 0.3	0.0 ± 0.1	-0.0 ± 0.0
Z_tr	0.0 ± 0.3	0.0 ± 0.1	-0.0 ± 0.0

Рисунок 2: Данные характеристик для нормального распределения




Рисунок 3: Гистограммы для распределения Коши

Коши $C(0,1)$

Статистика	n=10	n=100	n=1000
Среднее	1.7±68.4	8.1±215.9	-0.3±86.7
Медиана	0.0±0.6	-0.0±0.2	-0.0±0.0
Z_R	8.4±341.7	409.6±10792.7	-153.5±43327.5
Z_Q	-0.0±1.0	-0.0±0.2	0.0±0.1
Z_tr	-0.0±1.2	-0.0±0.2	-0.0±0.1

Рисунок 4: Данные характеристик для распределения Коши




Рисунок 5: Гистограммы для распределения Лапласа

Лапласа $L(0, 1/\sqrt{2})$

Статистика	n=10	n=100	n=1000
Среднее	-0.0±0.3	-0.0±0.1	-0.0±0.0
Медиана	-0.0±0.3	-0.0±0.1	0.0±0.0
Z_R	0.0±0.6	-0.0±0.7	-0.0±0.6
Z_Q	-0.0±0.3	-0.0±0.1	-0.0±0.0
Z_tr	-0.0±0.3	-0.0±0.1	-0.0±0.0

Рисунок 6: Данные характеристик для распределения Лапласа




Рисунок 7: Гистограммы для распределения Пуассона

Пуассона $P(5)$

Статистика	n=10	n=100	n=1000
Среднее	5.0±0.7	5.0±0.2	5.0±0.1
Медиана	4.8±0.9	4.9±0.3	5.0±0.0
Z_R	5.3±1.0	6.0±0.7	6.8±0.6
Z_Q	4.9±0.8	4.9±0.4	4.7±0.3
Z_tr	4.9±0.7	4.9±0.2	4.9±0.1

Рисунок 8: Данные характеристик для распределения Пуассона




Рисунок 9: Гистограммы для равномерного распределения

Равномерное $U(-\sqrt{3}, \sqrt{3})$

Статистика	n=10	n=100	n=1000
Среднее	-0.0±0.3	-0.0±0.1	-0.0±0.0
Медиана	-0.0±0.5	-0.0±0.2	-0.0±0.1
Z_R	-0.0±0.2	0.0±0.0	0.0±0.0
Z_Q	-0.0±0.4	-0.0±0.1	-0.0±0.0
Z_tr	-0.0±0.4	-0.0±0.1	-0.0±0.0

Рисунок 10: Данные характеристик для равномерного распределения

5. Обсуждение

В ходе выполнения лабораторной работы были построены гистограммы выборок объемом $n = 10, 100, 1000$ для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного, с наложением теоретических кривых плотности (или функции вероятности для распределения Пуассона).

Анализ гистограмм:

Объем выборки критически влияет на визуальное восприятие распределения. При $n = 10$ гистограммы всех распределений носят ярко выраженный случайный характер, форма распределения и его основные особенности

далеки от теоретических. При $n = 100$ форма распределений становится более узнаваемой: для нормального распределения прослеживается колоколообразная форма, для равномерного — приближение к прямоугольной, для Пуассона — характерная асимметрия. При $n = 1000$ гистограммы практически всех распределений хорошо аппроксимируют теоретические кривые, демонстрируя состоятельность гистограмм как оценки плотности распределения. Оптимальное число интервалов, подобранное по правилу Фридмана-Диакониса, позволило избежать как излишней зашумленности, так и чрезмерного сглаживания.

Анализ характеристик положения:

Множественные эксперименты (1000 повторений) позволили оценить математическое ожидание и дисперсию каждой характеристики. Полученные результаты сведены в таблицы выше и проанализированы ниже.

Нормальное распределение: Все характеристики состоятельны и сходятся к теоретическому значению 0.0. Наименьшую дисперсию при всех объёмах выборки имеет выборочное среднее, что подтверждает его эффективность для распределений без выбросов. Медиана и усечённое среднее незначительно уступают среднему по эффективности, но остаются вполне приемлемыми оценками. Полусумма экстремумов ожидаемо показала наибольшую дисперсию, особенно при малых n .

Распределение Коши: Яркая демонстрация проблемы робастности. Выборочное среднее и полусумма экстремумов показали высокую дисперсию, что делает их абсолютно непригодными для оценки центра ввиду тяжёлых хвостов распределения. В то же время медиана, полусумма квартилей и усечённое среднее оказались устойчивыми (робастными) оценками. Их значения стабильно близки к теоретической медиане (0), а дисперсия убывает с ростом n . Медиана показала наилучшую робастность.

Распределение Лапласа: Все характеристики сходятся к 0.0. Медиана и усечённое среднее демонстрируют меньшую дисперсию по сравнению с обычным средним. Это связано с более острым пиком и тяжёлыми хвостами распределения Лапласа, где робастные оценки показывают себя немного лучше. Полусумма экстремумов вновь оказалась наименее надёжной оценкой с высокой дисперсией.

Распределение Пуассона: Все характеристики сходятся к теоретическому значению 5. Выборочное среднее показывает наименьшую дисперсию при всех n , являясь наиболее эффективной оценкой для этого дискретного распределения. Медиана и Z_Q также хорошо работают, особенно при больших выборках. Полусумма экстремумов имеет систематическое

смещение вверх и большую дисперсию, так как чувствительна к редким большим значениям.

Равномерное распределение: Все оценки состоятельны и сходятся к 0.0. Наиболее эффективной оценкой здесь является полусумма экстремумов. Её дисперсия убывает значительно быстрее, чем у других характеристик. Это объясняется тем, что для распределения с чёткими границами минимум и максимум выборки быстро сходятся к истинным границам интервала.

Таким образом, результаты полностью соответствуют поставленным задачам и демонстрируют ключевые понятия математической статистики: состоятельность оценок и их робастность.

6. Выводы

В результате выполнения лабораторных работ №1 и №2 были достигнуты следующие результаты и сделаны выводы:

- Освоен метод гистограмм для визуализации распределений. Подтверждено, что с увеличением объёма выборки (от 10 до 1000) гистограмма всё лучше приближается к теоретической плотности распределения. При малых выборках ($n=10$) гистограмма малоинформативна и сильно подвержена случайности. Оптимальный выбор числа интервалов (по правилу Фридмана-Диакониса) является необходимым условием для получения адекватного представления о распределении.
- Для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) все исследованные выборочные характеристики положения являются состоятельными — их значения сходятся к теоретическим, а дисперсия убывает с ростом объёма выборки.
- На примере распределения Коши с тяжёлыми хвостами наглядно продемонстрирована проблема неробастности классического выборочного среднего. Среднее арифметическое и полусумма экстремумов показали крайне высокую дисперсию, что делает их непригодными для анализа данных с выбросами.
- Выбор оптимальной оценки:
 - а- Для нормального распределения и распределения Пуассона наиболее эффективной (с наименьшей дисперсией) является выборочное среднее.
 - б- Для распределений с тяжёлыми хвостами (Коши, Лапласа) наилучшей робастной оценкой является медиана. Также хорошую устойчивость показали полусумма квартилей и усечённое среднее.

- с- Для равномерного распределения уникально эффективной оценкой оказалась полусумма экстремальных элементов.
- Все поставленные в работе задачи выполнены. Полученные результаты полностью соответствуют теоретическим положениям о свойствах точечных оценок и позволяют сделать обоснованный выбор характеристик положения в зависимости от типа распределения и наличия выбросов.

7. Приложение

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

<https://github.com/KiselevaKsu/MathStatistics/tree/Lab1>