

Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №3
По дисциплине: «Математическая статистика»
Тема: «Боксплот Тьюки и анализ выбросов»

Выполнила студент: Киселева Ксения
учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург
2026

Оглавление

1. Постановка задачи.....	3
2. Теоретическая часть	3
3. Реализация	4
4. Результаты	5
5. Обсуждение.....	6
6. Выводы	8

1. Постановка задачи

Цель работы: изучение применения метода боксплот Тьюки для обработки и анализа одномерных распределений, проведение анализа влияния объёма выборки на долю отсеиваемых аномальных значений.

Задачи:

1. Сгенерировать выборки объёмом $n = 20$ и $n = 100$ для пяти законов распределения: нормального, Коши, Лапласа, Пуассона и равномерного.
2. Построить боксплоты Тьюки для полученных выборок, визуально оценить наличие выбросов.
3. Провести множественные эксперименты (1000 повторений) для каждого распределения и каждого объёма выборки, вычислить среднюю долю выбросов.
4. Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

2. Теоретическая часть

В работе исследуются пять законов распределения. Для непрерывных распределений (нормальное, Коши, Лапласа, равномерное) используется плотность вероятности $f(x)$, для дискретного (Пуассона) - функция вероятности $P(k)$.

1) Нормальное $N(x; 0,1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}; x \in \mathbb{R}$ (1)

2) Коши $C(x; 0,1); f(x) = \frac{1}{\pi(1+x^2)}; x \in \mathbb{R}$ (2)

3) Лапласа $L\left(x; 0, \frac{1}{\sqrt{2}}\right); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}; x \in \mathbb{R}$ (3)

4) Пуассона $P(k; 5); f(k) = \frac{5^k e^{-5}}{k!}; k = 0, 1, 2 \dots$ (4)

5) Равномерное $U(x; -\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases}$ (5)

Боксплот Тьюки - графический метод представления одномерных распределений, позволяющий визуально оценить медиану, квартили и наличие выбросов. Основные элементы боксплота:

- Нижняя граница ящика: первый квартиль Q_1 (25-й процентиль)
- Линия внутри ящика: медиана Q_2 (50-й процентиль)
- Верхняя граница ящика: третий квартиль Q_3 (75-й процентиль)
- Длина ящика: межквартильный размах $IQR = Q_3 - Q_1$
- Нижний ус: $Q_1 - 1.5 * IQR$

- Верхний ус: $Q_3 + 1.5 * IQR$
- Точки за пределами усов: потенциальные выбросы

Согласно методу Тьюки, выбросами считаются наблюдения, выходящие за пределы интервала:

$$[Q_1 - 1.5 * IQR; Q_3 + 1.5 * IQR]$$

Для каждой выборки объёма n доля выбросов вычисляется как:

$$p = \frac{\text{кол. — во выбросов}}{n}$$

При проведении множественных экспериментов (1000 повторений) средняя доля выбросов находится по формуле:

$$\bar{p} = \frac{1}{1000} \sum_{j=1}^{1000} p_j$$

3. Реализация

Язык программирования: Python 3.10

Среда разработки: Jupyter Notebook

Библиотеки:

- a. `pumpru` - для генерации случайных чисел и вычислений.
- b. `matplotlib.pyplot` для построения боксплотов.

Краткое описание методов:

- `cout_outliers(data)`-принимает на вход одномерный массив данных, вычисляет первый и третий квартили, межквартильный размах, определяет границы усов по правилу Тьюки и возвращает количество элементов, выходящих за эти границы (выбросов).

4. Результаты

Нормальное $N(0,1)$




Рисунок 1: Боксплоты Тьюки для выборок объёмом $n=20,100$ для нормального распределения

Коши $C(0,1)$




Рисунок 2: Боксплоты Тьюки для выборок объёмом $n=20,100$ для распределения Коши

Лапласа $L(0, 1/\sqrt{2})$




Рисунок 3: Боксплоты Тьюки для выборок объёмом $n=20,100$ для распределения Лапласа




Рисунок 4: Боксплоты Тьюки для выборок объёмом $n=20,100$ для распределения Пуассона




Рисунок 5: Боксплоты Тьюки для выборок объёмом $n=20,100$ для равномерного распределения

СРЕДНЯЯ ДОЛЯ ВЫБРОСОВ (1000 экспериментов)

Распределение	$n=20$	$n=100$	Теоретическая
Нормальное $N(0,1)$	0.0228	0.0110	0.007
Коши $C(0,1)$	0.1539	0.1565	0.150
Лапласа $L(0, 1/\sqrt{2})$	0.0760	0.0663	0.065
Пуассона $P(5)$	0.0229	0.0144	0.015
Равномерное $U(-\sqrt{3},\sqrt{3})$	0.0023	0.0000	0.000

Таблица 1: Средняя доля выбросов для различных распределений

5. Обсуждение

В ходе выполнения лабораторной работы были построены боксплоты Тьюки для выборок объёмом $n = 20, 100$ для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного (рисунки 1-5), и проведены множественные эксперименты (1000 повторений) для оценки средней доли выбросов в каждом распределении (таблица 1).

Анализ боксплотов:

Визуальный анализ боксплотов для конкретных выборок показывает, что распределение Коши, обладающее тяжёлыми хвостами, генерирует наибольшее количество выбросов: 3 при $n=20$ и 9 при $n=100$. Это полностью соответствует теоретическим представлениям: распределение Коши не имеет конечных моментов и часто порождает аномально далёкие от центра значения.

Для нормального распределения при $n=20$ выбросов не обнаружено, а при $n=100$ появился 1 выброс, что согласуется с вероятностью появления выбросов в нормально распределённых данных (около 0.7% теоретически). Распределение Лапласа показало 5 выбросов при $n=20$ и 11 при $n=100$, что отражает его более тяжёлые по сравнению с нормальным хвосты. Распределение Пуассона с параметром 5 не дало выбросов при $n=20$, но показало 2 выброса при $n=100$. Равномерное распределение, имеющее чёткие границы, не показало выбросов при обоих объёмах выборки, что ожидаемо.

Анализ средней доли выбросов (по 1000 экспериментам):

Множественные эксперименты позволили получить статистически надёжные оценки доли выбросов. Наибольшая доля выбросов наблюдается для распределения Коши: 15.39% при $n=20$ и 15.65% при $n=100$. Это подтверждает, что около 15.5% значений в выборках из распределения Коши классифицируются как выбросы по правилу Тьюки.

Для распределения Лапласа средняя доля выбросов составляет 7.60% при $n=20$ и 6.63% при $n=100$, что примерно в 3 раза выше, чем для нормального распределения (2.28% и 1.10% соответственно). Это отражает различие в форме хвостов: у распределения Лапласа они тяжелее, чем у нормального. Распределение Пуассона даёт 2.29% выбросов при $n=20$ и 1.44% при $n=100$. Небольшое снижение доли с ростом объёма выборки связано с тем, что при малых n возможны случайные колебания, создающие иллюзию выбросов. Равномерное распределение практически не даёт выбросов: 0.23% при $n=20$ и 0.00% при $n=100$. Небольшая доля при $n=20$ объясняется случайными колебаниями на малых выборках, когда границы усов могут временно захватывать крайние значения.

Влияние объёма выборки:

Для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) наблюдается уменьшение средней доли выбросов при увеличении n от 20 до 100. Это связано с тем, что с ростом объёма выборки эмпирические квартили лучше приближаются к теоретическим, границы усов становятся более стабильными, и доля ложных выбросов снижается.

Для распределения Коши доля выбросов остаётся практически неизменной (около 15.5%). Это характерная особенность распределений с тяжёлыми хвостами — вероятность появления экстремальных значений не убывает с ростом объёма выборки.

6. Выводы

В результате выполнения лабораторной работы №3 были получены следующие результаты и сделаны выводы:

- Освоен метод боксплотов Тьюки для визуализации одномерных распределений и обнаружения выбросов. Построены боксплоты для пяти распределений при объёмах выборок $n=20$ и $n=100$.
- Экспериментально определена средняя доля выбросов для каждого распределения путём проведения 1000 повторных экспериментов для $n=20$ и $n=100$ соответственно:
 - Нормальное: 2.28%, 1.10%
 - Коши: 15.39% , 15.65%
 - Лапласа: 7.10%, 6.63%
 - Пуассона: 2.29% , 1.44%
 - Равномерное: 0.23% , 0.00%
- Выявлено влияние объёма выборки на долю выбросов:
 - a. Для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) доля выбросов уменьшается с ростом n
 - b. Для распределения Коши с тяжёлыми хвостами доля выбросов остаётся стабильной (около 15.5%) и не зависит от объёма выборки
- Наибольшая доля выбросов характерна для распределения Коши, наименьшая для равномерного. Распределение Лапласа занимает промежуточное положение, что отражает степень "тяжести" его хвостов. Полученные результаты хорошо согласуются с теоретическими ожиданиями и демонстрируют эффективность боксплота Тьюки для выявления аномальных значений.

7. Приложение

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

<https://github.com/KiselevaKsu/MathStatistics/tree/Lab3>