

Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №3
По дисциплине: «Математическая статистика»
Тема: «Боксплот Тьюки и анализ выбросов»

Выполнила студент: Киселева Ксения
учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург
2026

Оглавление

1. Постановка задачи.....	3
2. Теоретическая часть	3
3. Реализация	4
4. Результаты	4
5. Обсуждение.....	5
6. Выводы	6

1. Постановка задачи

Цель работы: изучение применения метода боксплот Тьюки для обработки и анализа одномерных распределений, проведение анализа влияния объёма выборки на долю отсеиваемых аномальных значений.

Задачи:

1. Сгенерировать выборки объёмом $n = 20$ и $n = 100$ для пяти законов распределения: нормального, Коши, Лапласа, Пуассона и равномерного.
2. Построить боксплоты Тьюки для полученных выборок, визуально оценить наличие выбросов.
3. Провести множественные эксперименты (1000 повторений) для каждого распределения и каждого объёма выборки, вычислить среднюю долю выбросов.
4. Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.

2. Теоретическая часть

В работе исследуются пять законов распределения. Для непрерывных распределений (нормальное, Коши, Лапласа, равномерное) используется плотность вероятности $f(x)$, для дискретного (Пуассона) - функция вероятности $P(k)$.

1) Нормальное $N(x; 0,1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}; x \in \mathbb{R}$ (1)

2) Коши $C(x; 0,1); f(x) = \frac{1}{\pi(1+x^2)}; x \in \mathbb{R}$ (2)

3) Лапласа $L(x; 0, \frac{1}{\sqrt{2}}); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}; x \in \mathbb{R}$ (3)

4) Пуассона $P(k; 5); f(k) = \frac{5^k e^{-5}}{k!}; k = 0, 1, 2 \dots$ (4)

5) Равномерное $U(x; -\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases}$ (5)

Боксплот Тьюки - графический метод представления одномерных распределений, позволяющий визуально оценить медиану, квартили и наличие выбросов. Основные элементы боксплота:

- Нижняя граница ящика: первый квартиль Q_1 (25-й процентиль)
- Линия внутри ящика: медиана Q_2 (50-й процентиль)
- Верхняя граница ящика: третий квартиль Q_3 (75-й процентиль)
- Длина ящика: межквартильный размах $IQR = Q_3 - Q_1$
- Нижний ус: $Q_1 - 1.5 * IQR$

- Верхний ус: $Q_3 + 1.5 * IQR$
- Точки за пределами усов: потенциальные выбросы

Согласно методу Тьюки, выбросами считаются наблюдения, выходящие за пределы интервала:

$$[Q_1 - 1.5 * IQR; Q_3 + 1.5 * IQR]$$

Для каждой выборки объёма n доля выбросов вычисляется как:

$$p = \frac{\text{кол. во выбросов}}{n}$$

При проведении множественных экспериментов (1000 повторений) средняя доля выбросов находится по формуле:

$$\bar{p} = \frac{1}{1000} \sum_{j=1}^{1000} p_j$$

3. Реализация

Язык программирования: Python 3.10

Среда разработки: Jupyter Notebook

Библиотеки:

- a. numpy - для генерации случайных чисел и вычислений.
- b. matplotlib.pyplot для построения боксплотов.

Краткое описание методов:

- `scout_outliers(data)`-принимает на вход одномерный массив данных, вычисляет первый и третий квартили, межквартильный размах, определяет границы усов по правилу Тьюки и возвращает количество элементов, выходящих за эти границы (выбросов).

4. Результаты




Рисунок 1: Боксплоты Тьюки для выборок объёмом $n=20$



Рисунок 2: Боксплоты Тьюки для выборок объёмом $n=100$

СРЕДНЯЯ ДОЛЯ ВЫБРОСОВ (1000 экспериментов)		
Распределение	$n=20$	$n=100$
Нормальное $N(0,1)$	0.0225	0.0106
Коши $C(0,1)$	0.1488	0.1550
Лапласа $L(0, 1/\sqrt{2})$	0.0710	0.0656
Пуассона $P(5)$	0.0257	0.0140
Равномерное $U(-\sqrt{3}, \sqrt{3})$	0.0035	0.0000

Таблица 1: Средняя доля выбросов для различных распределений

5. Обсуждение

В ходе выполнения лабораторной работы были построены боксплоты Тьюки для выборок объёмом $n = 20, 100$ для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного (рисунки 1-2), и проведены множественные эксперименты (1000 повторений) для оценки средней доли выбросов в каждом распределении (таблица 1).

Анализ боксплотов:

Визуальный анализ боксплотов для конкретных выборок (рисунки 1-2) показывает, что распределение Коши, обладающее тяжёлыми хвостами, генерирует наибольшее количество выбросов: 3 при $n=20$ и 11 при $n=100$. Это полностью соответствует теоретическим представлениям: распределение Коши не имеет конечных моментов и часто порождает аномально далёкие от центра значения.

Для нормального распределения при $n=20$ выбросов не обнаружено, а при $n=100$ появилось 3 выброса, что согласуется с вероятностью появления выбросов в нормально распределённых данных (около 0.7% теоретически). Распределение Лапласа показало 0 выбросов при $n=20$ и 7 выбросов при $n=100$, что отражает его более тяжёлые по сравнению с нормальным хвосты.

Распределение Пуассона с параметром 5 не дало выбросов в конкретных выборках (0 при обоих объёмах), что объясняется дискретной природой распределения и ограниченным диапазоном значений. Равномерное

распределение, имеющее чёткие границы, также не показало выбросов, что ожидаемо.

Анализ средней доли выбросов (по 1000 экспериментам):

Множественные эксперименты позволили получить статистически надёжные оценки доли выбросов (таблица 1). Наибольшая доля выбросов наблюдается для распределения Коши: 14.88% при $n=20$ и 15.50% при $n=100$. Это подтверждает, что около 15% значений в выборках из распределения Коши классифицируются как выбросы по правилу Тьюки.

Для распределения Лапласа средняя доля выбросов составляет 7.10% при $n=20$ и 6.56% при $n=100$, что примерно в 3 раза выше, чем для нормального распределения (2.25% и 1.06% соответственно). Это отражает различие в форме хвостов: у распределения Лапласа они тяжелее, чем у нормального.

Распределение Пуассона даёт 2.57% выбросов при $n=20$ и 1.40% при $n=100$. Небольшое снижение доли с ростом объёма выборки связано с тем, что при малых n возможны случайные флуктуации(колебания), создающие иллюзию выбросов.

Равномерное распределение практически не даёт выбросов: 0.35% при $n=20$ и 0% при $n=100$. Небольшая доля при $n=20$ объясняется случайными флуктуациями на малых выборках, когда из-за дискретности данных границы услов могут временно захватывать крайние значения.

Влияние объёма выборки:

Для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) наблюдается уменьшение средней доли выбросов при увеличении n от 20 до 100. Это связано с тем, что с ростом объёма выборки эмпирические квартили лучше приближаются к теоретическим, границы услов становятся более стабильными, и доля ложных выбросов снижается.

Для распределения Коши доля выбросов остаётся практически неизменной (около 15%). Это характерная особенность распределений с тяжёлыми хвостами - вероятность появления экстремальных значений не убывает с ростом объёма выборки, а остаётся постоянной.

6. Выводы

В результате выполнения лабораторной работы №3 были получены следующие результаты и сделаны выводы:

- Освоен метод боксплотов Тьюки для визуализации одномерных распределений и обнаружения выбросов. Построены боксплоты для пяти распределений при объёмах выборок $n=20$ и $n=100$.

- Экспериментально определена средняя доля выбросов для каждого распределения путём проведения 1000 повторных экспериментов для $n=20$ и $n=100$ соответственно:
 - Нормальное: 2.25%, 1.06%
 - Коши: 14.88% , 15.50%
 - Лапласа: 7.10%, 6.56%
 - Пуассона: 2.57% , 1.40%
 - Равномерное: 0.35% , 0.00%
- Выявлено влияние объёма выборки на долю выбросов:
 - а. Для распределений с конечной дисперсией (нормальное, Лапласа, Пуассона, равномерное) доля выбросов уменьшается с ростом n
 - б. Для распределения Коши с тяжёлыми хвостами доля выбросов остаётся стабильной (15%) и не зависит от объёма выборки
- Наибольшая доля выбросов характерна для распределения Коши, наименьшая для равномерного. Распределение Лапласа занимает промежуточное положение, что отражает степень "тяжести" его хвостов.

7. Приложение

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

<https://github.com/KiselevaKsu/MathStatistics/tree/Lab3>