

Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт

Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №4

По дисциплине: «Математическая статистика»

**Тема: «Эмпирическая функция распределения и ядерные оценки
плотности»**

Выполнила студент: Киселева Ксения
учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург

2026

Оглавление

1. Постановка задачи.....	3
2. Теоретическая часть	3
3. Реализация	4
4. Результаты	4
5. Обсуждение.....	8
6. Выводы	9

1. Постановка задачи

Цель работы: изучение эмпирической функции распределения и ядерных оценок плотности, анализ влияния мощности выборки на точность приближения эмпирической функции к истинным функциям распределения. Задачи:

- Сгенерировать выборки различного объема ($n = 20, 60, 100$) для пяти законов распределения: нормального, Коши, Лапласа, Пуассона и равномерного.
- Для каждого распределения построить графики эмпирической функции распределения и наложить на них теоретическую функцию распределения.
- Построить ядерные оценки плотности (с гауссовым ядром) и наложить на них теоретические кривые плотности.
- Проанализировать, как объём выборки влияет на сходимость эмпирической функции к теоретической.
- Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.

2. Теоретическая часть

В работе исследуются пять законов распределения. Для непрерывных распределений (нормальное, Коши, Лапласа, равномерное) используется плотность вероятности $f(x)$, для дискретного (Пуассона) — функция вероятности $P(k)$.

1) Нормальное $N(x; 0,1); f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}; x \in \mathbb{R}$ (1)

2) Коши $C(x; 0,1); f(x) = \frac{1}{\pi(1+x^2)}; x \in \mathbb{R}$ (2)

3) Лапласа $L(x; 0, \frac{1}{\sqrt{2}}); f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}; x \in \mathbb{R}$ (3)

4) Пуассона $P(k; 10); P(k) = \frac{10^k e^{-10}}{k!}; k = 0, 1, 2, \dots$ (4)

5) Равномерное $U(x; -\sqrt{3}, \sqrt{3}); f(x) = \begin{cases} \frac{1}{2\sqrt{3}}, & x \in [-\sqrt{3}; \sqrt{3}] \\ 0, & x \notin [-\sqrt{3}; \sqrt{3}] \end{cases}$ (5)

Пусть имеется выборка $x_1, x_2, \dots, x_n$ из некоторого распределения.

Эмпирическая функция распределения определяется как:

$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(x_i \leq x)$, где I – индикаторная функция, равная 1, если условие выполняется, и 0 в противном случае. $F_n(x)$ – неубывающая ступенчатая функция, $\lim_{x \rightarrow -\infty} F_n(x) = 0$, $\lim_{x \rightarrow +\infty} F_n(x) = 1$.

Теорема Гливенко-Кантелли: $\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \rightarrow_{n \rightarrow \infty} 0$, где $F(x)$ – теоретическая функция распределения. Теорема утверждает, что

эмпирическая функция распределения сходится к теоретической равномерно по x при увеличении объёма выборки.

Гистограмма является простейшей оценкой плотности распределения, однако она имеет ступенчатый вид и чувствительна к выбору количества интервалов. Ядерная оценка плотности лишена этих недостатков и представляет собой гладкую функцию. Ядерная оценка плотности в точке x определяется формулой:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x-x_i}{h}\right), \text{ где } K\left(\frac{x-x_i}{h}\right) = \frac{1}{\sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{x-x_i}{h}\right)^2} - \text{гауссово ядро, } h -$$

ширина полосы, x – выбранная точка, x_i – точка из выборки, n – количество элементов в выборке.

3. Реализация

Язык программирования: Python 3.14

Среда разработки: Jupyter Notebook

Библиотеки:

- a. `numpy` - для генерации случайных чисел и вычислений.
- b. `scipy.stats` - для работы с теоретическими функциями распределения и ядерным сглаживанием.
- c. `matplotlib.pyplot` для построения графиков.

Краткое описание методов:

- `plot_ecdf(samples, sizes, name)` — принимает на вход список выборок, их объёмы и название распределения; строит эмпирическую функцию распределения (ступенчатую линию) и накладывает на неё теоретическую функцию распределения; возвращает график.
- `plot_kde(samples, sizes, name)` — принимает на вход список выборок, их объёмы и название распределения; вычисляет ядерную оценку плотности с помощью `stats.gaussian_kde` (гауссово ядро), строит её и накладывает теоретическую кривую плотности (или функцию вероятности для Пуассона); возвращает график.
- `run_lab4()` — основная функция, которая генерирует выборки для всех пяти распределений и трёх объёмов ($n = 20, 60, 100$), затем последовательно вызывает функции построения графиков для каждого распределения.
- `plot_kde_with_h_demo()` — принимает на вход выборки равномерного распределения и распределения Коши ($n=100$), строит ядерные оценки плотности с разными значениями ширины окна h , демонстрируя влияние этого параметра на качество сглаживания.

4. Результаты




Рисунок 1: ЭФР для нормального распределения




Рисунок 2: Ядерная оценка плотности для нормального распределения



Рисунок 3: ЭФР для распределения Коши




Рисунок 4: Ядерная оценка плотности для распределения Коши



Рисунок 5: ЭФР для распределения Лапласа




Рисунок 6: Ядерная оценка плотности для распределения Лапласа




Рисунок 7: ЭФР для равномерного распределения




Рисунок 8: Ядерная оценка плотности для равномерного распределения

Пуассон(10) — ЭФР, кумулятивная гистограмма и теоретическая функция




Рисунок 8: ЭФР для распределения Пуассона(10)




Рисунок 10: Ядерная оценка плотности для распределения Пуассона(10)





Рисунок 11 – Влияние ширины окна h на ядерную оценку плотности для равномерного распределения ($n = 100$)



5. Обсуждение

В ходе выполнения лабораторной работы были построены графики эмпирических функций распределения и ядерных оценок плотности для выборок объёмом $n = 20, 60, 100$ для пяти распределений: нормального, Коши, Лапласа, Пуассона и равномерного.

Анализ эмпирической функции распределения:

По графикам видно, что с увеличением объёма выборки эмпирическая функция распределения всё лучше приближается к теоретической. При $n = 20$ наблюдаются заметные отклонения и выраженная ступенчатость, при $n = 60$ совпадение становится лучше, а при $n = 100$ ЭФР практически совпадает с теоретической функцией, что подтверждает теорему Гливенко-Кантелли - с ростом объёма выборки эмпирическая функция распределения сходится к теоретической. Для распределения Коши отклонения более заметны из-за тяжёлых хвостов. Для дискретного распределения Пуассона обе функции имеют ступенчатый вид, и с ростом n эмпирические ступеньки приближаются к теоретическим.

Дополнительно на графиках была построена кумулятивная гистограмма (накопленные частоты). При малых n она может отличаться от ЭФР из-за способа группировки данных в интервалы, но с ростом n обе ступенчатые функции сближаются между собой и с теоретической кривой. Для дискретного распределения Пуассона кумулятивная гистограмма строится по целочисленным интервалам и также демонстрирует сходимость к теоретической функции распределения.

Анализ ядерной оценки плотности:

Ядерная оценка даёт сглаженное приближение плотности распределения. Для нормального распределения она хорошо совпадает с теоретической и улучшается при увеличении выборки. Для равномерного распределения границы сглаживаются, поэтому форма отличается от теоретической. Для распределения Коши возможны искажения из-за выбросов. Для Пуассона ядерная оценка даёт гладкую кривую, тогда как теоретическая плотность дискретна (отдельные точки); при $n = 100$ ядерная оценка хорошо повторяет форму распределения. В целом ядерная оценка позволяет оценить форму распределения, однако не всегда позволяет точно определить его тип.

Для демонстрации влияния параметра сглаживания h были построены ядерные оценки плотности для равномерного распределения и распределения Коши при $n = 100$ с различными значениями h (рисунки 11-12). Для равномерного распределения оптимальным оказалось $h = 0.3$: при этом

значении границы распределения не сглажены, но кривая остаётся достаточно гладкой. Для распределения Коши оптимальное значение составило $h = 0.4$, что позволяет учесть тяжёлые хвосты и избежать излишней зашумлённости. Правило Сильвермана, хорошо работающее для нормального распределения, Лапласа и Пуассона, для равномерного и Коши может давать неоптимальные результаты, поэтому в таких случаях требуется ручной подбор параметра.

6. Выводы

По результатам лабораторной работы можно сделать следующие выводы. Увеличение объёма выборки приводит к более точному приближению эмпирической функции распределения к теоретической.

Сравнение ЭФР и кумулятивной гистограммы: Оба метода дают ступенчатые оценки функции распределения. При малых n кумулятивная гистограмма может отличаться от ЭФР из-за группировки данных, но с ростом выборки различия исчезают. Для дискретного распределения Пуассона обе оценки также сходятся к теории.

Ядерная оценка плотности позволяет получить сглаженное приближение плотности распределения и в большинстве случаев хорошо согласуется с теоретической функцией.

Для распределений с тяжёлыми хвостами, таких как распределение Коши, требуется большой объём выборки для получения устойчивых статистических оценок.

При малых объёмах выборки оценки распределения могут существенно отклоняться от теоретических значений и сильнее зависят от случайных колебаний выборки.

Параметр сглаживания h существенно влияет на качество ядерной оценки плотности. Для равномерного распределения оптимальным является $h = 0.3$, для распределения Коши — $h = 0.4$. Правило Сильвермана, дающее хорошие результаты для нормального распределения, для равномерного и Коши требует корректировки, что подтверждает необходимость анализа данных перед выбором метода оценки.

7. Приложение

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

<https://github.com/KiselevaKsu/MathStatistics/tree/Lab4>