

Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №5
По дисциплине: «Математическая статистика»

Тема: «Корреляционный анализ и эллипсы рассеивания»

Выполнила студент: Киселева Ксения
учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург
2026

Оглавление

1. Постановка задачи.....	3
2. Теоретическая часть	3
3. Реализация	5
4. Результаты	6
5. Обсуждение.....	7
6. Выводы	8

1. Постановка задачи

Цель работы: изучение методов корреляционного анализа для двумерных данных, визуализация ковариационной структуры с помощью эллипсов рассеивания, сравнение различных оценок коэффициента корреляции.

Задачи:

- Сгенерировать двумерные выборки (x, y) объёмом $n = 20, 60, 100$ из:
 - Двумерного нормального распределения $N(0, 0, 1, 1, \rho)$ с параметрами $\rho = 0, 0.5, 0.9$
 - Смеси: $0.9 * N(0, 0, 1, 1, 0.9) + 0.1 * N(0, 0, 10, 10, -0.9)$
- Для каждой выборки вычислить три коэффициента корреляции:
 - Пирсона
 - Спирмена
 - Квадрантный
- Провести множественные эксперименты (1000 повторений) для каждого распределения и объёма выборки, вычислить среднее и дисперсию каждого коэффициента.
- Построить эллипсы равновероятности для визуализации структуры данных.

2. Теоретическая часть

Двумерная случайная величина (X, Y) называется распределённой нормально, если её плотность вероятности имеет вид:

$$N(x, y, \bar{x}, \bar{y}, \sigma_x, \sigma_y, \rho) \\ = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp\left(-\frac{1}{2(1-\rho^2)}\left[\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\rho\frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2}\right]\right)$$

где $\bar{x}, \bar{y}$ - математические ожидания X, Y ,

σ_x^2, σ_y^2 - дисперсии X, Y ,

ρ - коэффициент корреляции между X, Y .

В работе используются параметры $\bar{x} = 0, \bar{y} = 0, \sigma_x = 1, \sigma_y = 1, \rho = 0, 0.5, 0.9$.

Для исследования устойчивости коэффициентов корреляции к выбросам используется смесь двух нормальных распределений: $0.9 * N(0, 0, 1, 1, 0.9) + 0.1 * N(0, 0, 10, 10, -0.9)$. Смесь состоит из 90% точек с сильной положительной корреляцией $\rho = 0.9$ и малой дисперсией и 10% точек с сильной отрицательной корреляцией $\rho = -0.9$ и большой дисперсией.

Выборочный коэффициент корреляции Пирсона вычисляется по формуле:

$$r = \frac{\frac{1}{n} \sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\frac{1}{n} \sum (x_i - \bar{x})^2 * \frac{1}{n} \sum (y_i - \bar{y})^2}} = \frac{K}{s_X s_Y}$$

где K - выборочная ковариация, s_X^2, s_Y^2 - выборочные дисперсии.

Коэффициент Пирсона измеряет силу линейной связи между переменными и принимает значения от -1 до 1.

Выборочный квадрантный коэффициент корреляции:

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n}$$

где n_1, n_2, n_3, n_4 - количества точек с координатами (x_i, y_i) , попавшими соответственно в 1, 2, 3, 4 квадранты декартовой системы с осями $x' = x - med\ x, y' = y - med\ y$ и с центром в точке с координатами $(med\ x, med\ y)$. Квадрантный коэффициент устойчив к выбросам, так как использует медианы и знаки отклонений.

Выборочный коэффициент ранговой корреляции Спирмена — это выборочный коэффициент корреляции Пирсона, вычисленный по рангам наблюдений u, v :

$$r_S = \frac{\frac{1}{n} \sum (u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\frac{1}{n} \sum (u_i - \bar{u})^2 * \frac{1}{n} \sum (v_i - \bar{v})^2}}$$

где $\bar{u} = \bar{v} = \frac{1+2+\dots+n}{n} = \frac{n+1}{2}$ - среднее значение рангов. Коэффициент

Спирмена оценивает монотонную (не обязательно линейную) связь и также устойчив к выбросам.

Расчёт коэффициента корреляции для смеси распределений: Дисперсия симметрична для x и y , поэтому общая: $D = 0.9^2 * D_1 + 0.1^2 * D_2 = 0.91$
Коэффициент ковариации:

$$cov(X, Y) = 0.9^2 * 0.9 + 0.1^2 * (-0.9) * \sqrt{10} * \sqrt{10} = 0.639$$

Коэффициент корреляции:

$$r_{xy} = \frac{cov(X, Y)}{\sqrt{D_X} \sqrt{D_Y}} = \frac{0.639}{\sqrt{0.91} \sqrt{0.91}} \approx 0.702$$

Для двумерного нормального распределения эллипс, содержащий $\rho * 100\%$ точек, задаётся уравнением:

$$\frac{(x - \bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x - \bar{x})(y - \bar{y})}{\sigma_x \sigma_y} + \frac{(y - \bar{y})^2}{\sigma_y^2} = const$$

Или в более общем виде для доверительной вероятности p :

$$\frac{(x - \bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x - \bar{x})(y - \bar{y})}{\sigma_x \sigma_y} + \frac{(y - \bar{y})^2}{\sigma_y^2} = \chi_2^2(p) * (1 - \rho^2)$$

где $\chi^2_2(p)$ - квантиль распределения хи-квадрат с 2 степенями свободы (при $p = 0.95, \chi^2_2 \approx 5.99$).

3. Реализация

Язык программирования: Python 3.14

Среда разработки: Jupyter Notebook

Библиотеки:

- a. numpy - для генерации случайных чисел, вычисления средних, дисперсий, ковариаций и собственных значений.
- b. scipy.stats - для вычисления коэффициента корреляции Спирмена и квантилей хи-квадрат.
- c. scipy.stats.chi2 — для получения значения хи-квадрат при построении эллипсов.
- d. matplotlib.patches.Ellipse — для рисования эллипсов равновероятности.
- e. matplotlib.pyplot для построения графиков.

Краткое описание методов:

- `pearson_corr(x, y)` — принимает на вход два массива данных одинаковой длины, вычисляет коэффициент корреляции Пирсона с помощью функции `np.corrcoef()`, возвращает число от -1 до 1, характеризующее силу линейной связи.
- `spearman_corr(x, y)` — принимает на вход два массива данных, вычисляет коэффициент ранговой корреляции Спирмена с помощью `stats.spearmanr()`, возвращает число от -1 до 1, характеризующее силу монотонной связи.
- `quadrant_corr(x, y)` — принимает на вход два массива данных, вычисляет квадрантный коэффициент корреляции: находит медианы X и Y, определяет для каждой точки её квадрант относительно медиан.
- `generate_bivariate_normal(n, rho)` — принимает объём выборки n и коэффициент корреляции ρ , генерирует выборку из двумерного нормального распределения с параметрами (0, 0, 1, 1, 0.9) с помощью `np.random.multivariate_normal()`, возвращает два массива X и Y.
- `generate_mixture(n)` — принимает объём выборки n, генерирует смесь: 90% точек из $N(0, 0, 1, 1, 0.9)$ и 10% точек из $N(0, 0, 10, 10, -0.9)$, возвращает два массива X и Y.
- `add_ellipse(ax, x, y, color)` — принимает оси графика, массивы X и Y, цвет; вычисляет средние, ковариационную матрицу, собственные значения и векторы, угол поворота; строит эллипс равновероятности с доверительным уровнем 95% ($\chi^2 = 5.99$).
- `run_experiment(generator, n, n_iterations)` — принимает функцию-генератор выборки, объём n и количество повторений (1000); для каждой итерации вычисляет три коэффициента корреляции;

возвращает словарь со средними и дисперсиями каждого коэффициента.

4. Результаты

Средние значения коэффициентов корреляции (1000 экспериментов):

Распределение	n = 20		n = 60		n = 100	
	r	D	r	D	r	D
Нормальное $\rho = 0$	0.0033	0.052996	-0.0002	0.017160	-0.0048	0.010336
Нормальное $\rho = 0.5$	0.4963	0.031192	0.4919	0.009175	0.4970	0.006222
Нормальное $\rho = 0.9$	0.8944	0.002492	0.8981	0.000720	0.8997	0.000380
Смесь	0.1151	0.189132	0.0199	0.078718	0.0021	0.050275

Таблица 1 – Коэффициент Пирсона r для разных n

Распределение	n = 20		n = 60		n = 100	
	r_s	D	r_s	D	r_s	D
Нормальное $\rho = 0$	0.0050	0.051924	0.0011	0.017376	-0.0051	0.010576
Нормальное $\rho = 0.5$	0.4608	0.035019	0.4726	0.010278	0.4767	0.007031
Нормальное $\rho = 0.9$	0.8630	0.004898	0.8826	0.001216	0.8867	0.000610
Смесь	0.5177	0.023355	0.5356	0.006798	0.5360	0.004272

Таблица 2 – Коэффициент Спирмена r_s для разных n

Распределение	n = 20		n = 60		n = 100	
	r_Q	D	r_Q	D	r_Q	D
Нормальное $\rho = 0$	0.0112	0.054915	0.0009	0.016381	-0.0012	0.010515
Нормальное $\rho = 0.5$	0.3150	0.048335	0.3329	0.014009	0.3301	0.009546
Нормальное $\rho = 0.9$	0.6860	0.029564	0.7043	0.008861	0.7094	0.005118
Смесь	0.5332	0.025938	0.5608	0.008721	0.5640	0.005003

Таблица 3 – Квадрантный коэффициент r_Q для разных n

На рисунках 1-4 представлены эллипсы рассеяния равновероятности (доверительный уровень 95%) для выборок объёмом $n = 20, 60, 100$.



Рисунок 1: Двумерное нормальное распределение для выборки $n = 20$




Рисунок 2: Двумерное нормальное распределение для выборки $n = 60$



Рисунок 3: Двумерное нормальное распределение для выборки $n = 100$




Рисунок 4: Смесь распределений для выборок $n = 20, 60, 100$

5. Обсуждение

В ходе выполнения лабораторной работы были сгенерированы двумерные выборки объёмом $n = 20, 60, 100$ для трёх случаев двумерного нормального распределения и для смеси распределений. Для каждой выборки вычислялись три коэффициента корреляции: Пирсона r , Спирмена r_s и квадрантный r_Q . Эксперимент повторялся 1000 раз для получения средних значений и дисперсий.

С ростом объёма выборки дисперсия всех трёх коэффициентов (Пирсона, Спирмена, квадрантного) уменьшается для всех распределений, что подтверждает состоятельность оценок.

Двумерное нормальное распределение:

Наилучшее приближение к истинному коэффициенту корреляции ρ показал коэффициент Пирсона. При $\rho = 0.9$ его среднее значение составило 0.8997 при $n = 100$, а дисперсия — 0.0004. Квадрантный коэффициент показал худшие результаты: при $\rho = 0.9$ его среднее значение составило лишь 0.7094, что значительно ниже истинного. Коэффициент Спирмена занял промежуточное положение (0.8867 при $\rho = 0.9$).

Смесь распределений:

Добавление 10% выбросов (с $\rho = -0.9$ и дисперсией 10) существенно исказило результаты. Коэффициент Пирсона "провалился" — его среднее значение при $n = 100$ составило 0.0021 (вместо ожидаемых 0.5-0.6). Спирмен и квадрантный оказались робастными: их значения сохранились на уровне 0.5360 и 0.5640 соответственно. Дисперсия Пирсона осталась большой (0.0503), тогда как у Спирмена и квадрантного она мала (0.0043 и 0.0050).

Эллипсы рассеяния:

Для двумерного нормального распределения с ростом ρ эллипс закономерно "сплющивается" и вытягивается вдоль прямой $y = x$. При $\rho = 0$ эллипс имеет круглую форму, при $\rho = 0.5$ — умеренно вытянут, при $\rho = 0.9$ — сильно вытянут. Это визуально подтверждает наличие линейной зависимости между координатами.

Для смеси распределений эллипсы становятся более размытыми из-за выбросов, их ориентация и степень сжатия меняются, что затрудняет визуальное определение исходной зависимости.

6. Выводы

В ходе выполнения лабораторной работы было выявлено:

- Сходимость оценок. С увеличением объема выборки (от 20 до 100) дисперсия всех исследуемых коэффициентов корреляции уменьшается, что подтверждает их состоятельность.
- Выбор коэффициента для нормального распределения. Для двумерного нормального распределения наиболее точным является коэффициент Пирсона. При $\rho = 0.9$ он дал среднее 0.8997 и минимальную дисперсию 0.0004. Квадрантный коэффициент показал наихудшие результаты, Спирмен занял промежуточное положение.
- Влияние выбросов (смесь). Добавление 10% данных с высокой дисперсией и отрицательной корреляцией существенно исказило картину. Коэффициент Пирсона "провалился", тогда как Спирмен и квадрантный сохранили устойчивость. Это демонстрирует необходимость использования робастных оценок при наличии аномальных значений.

- Визуализация эллипсов. При увеличении ρ эллипс закономерно вытягивается вдоль прямой $y = x$, что наглядно подтверждает линейную зависимость между координатами. Для смеси распределений эллипсы теряют чёткую структуру из-за выбросов.
- Для анализа данных с потенциальными выбросами предпочтительнее использовать коэффициент ранговой корреляции Спирмена, который сочетает робастность и достаточную точность.

7. Приложение

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

<https://github.com/KiselevaKsu/MathStatistics/tree/Lab5>