

Санкт-Петербургский Политехнический
Университет Петра Великого
Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

Отчет по лабораторной работе №6
По дисциплине: «Математическая статистика»

Тема: «Линейная регрессия. Метод наименьших квадратов и
наименьших модулей»

Выполнила студент: Киселева Ксения
учебной группы 5030102/30202

Преподаватель: Баженов А.Н.

Санкт-Петербург
2026

Оглавление

1. Постановка задачи.....	3
2. Теоретическая часть	3
3. Реализация	5
4. Результаты	6
5. Обсуждение.....	7
6. Выводы	8

1. Постановка задачи

Цель работы: изучение методов линейной регрессии (метода наименьших квадратов и метода наименьших модулей), сравнение их устойчивости к выбросам.

Задачи:

- I. Задать равномерные значения x_i на отрезке $[-1.8; 2]$ с шагом 0.2 (20 точек).
- II. Сгенерировать $y_i = 2 + 2x_i + \varepsilon_i$, где $\varepsilon_i \sim N(0,1)$ - нормально распределённая случайная ошибка.
- III. Оценить параметры a, b (коэффициенты регрессии $y = a + bx$) двумя методами:
 - a. Метод наименьших квадратов (МНК)
 - b. Метод наименьших модулей (МНМ)
- IV. Повторить пункты I-III, добавив выбросы:
$$y_1 \leftarrow y_1 + 10, y_{20} \leftarrow y_{20} - 10.$$
- V. Для каждого метода вычислить абсолютную погрешность $\Delta = |z - \hat{z}|$ и относительную погрешность $\delta = \frac{|z - \hat{z}|}{z} * 100\%$, где z - точное значение, $\hat{z}$ - приближённое значение.
- VI. Сравнить устойчивость МНК и МНМ к выбросам, построить графики регрессионных прямых и исходных данных.

2. Теоретическая часть

2.1 Модель простой линейной регрессии

Регрессионную модель описания данных называют простой линейной регрессией, если

$$y_i = a + bx_i + \varepsilon_i, i = 1, \dots, n,$$

где x_i - заданные числа (значения фактора), y_i - наблюдаемые значения отклика, ε_i - независимые, нормально распределённые с нулевым математическим ожиданием и одинаковой дисперсией случайные величины (наблюдаемые ошибки), a, b - неизвестные параметры (свободный член и коэффициент наклона).

Регрессионная модель с шумом:

$$y_i = a + bx_i + \varepsilon_i + 10 * I(i), I(i) = 1_{\{i=0\}} - 1_{\{i=n-1\}}$$

В работе используется модель с истинными значениями параметров $a = 2, b = 2$.

2.2 Метод наименьших квадратов

При оценивании параметров регрессионной модели вводится критерий рассогласования отклика и регрессионной функции. Оценки параметров определяются так, чтобы сделать это рассогласование наименьшим.

МНК минимизирует сумму квадратов остатков:

$$Q(a, b) = \sum_{i=1}^n \varepsilon_i^2 = \sum_{i=1}^n (y_i - a - bx_i)^2 \rightarrow \min_{a,b} \quad (1)$$

Задача минимизации квадратичного критерия (1) носит название задачи метода наименьших квадратов, а оценки, реализующие минимум, называют МНК-оценками.

Решение имеет аналитический вид:

- МНК-оценка наклона прямой регрессии:

$$\hat{b} = \frac{\overline{xy} - \bar{x} * \bar{y}}{\overline{x^2} - (\bar{x})^2} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}, \overline{x^2} - (\bar{x})^2 = \frac{1}{n} \sum (x_i - \bar{x})^2 = s_x^2 > 0$$

(при наличии различных x_i).

- МНК-оценка свободного члена:

$$\hat{a} = \bar{y} - \hat{b}\bar{x}$$

МНК чувствителен к выбросам (ошибки возводятся в квадрат).

2.3 Метод наименьших модулей

МНМ минимизирует сумму абсолютных отклонений:

$$\sum_{i=1}^n |y_i - a - bx_i| \rightarrow \min_{a,b} \quad (2)$$

В отличие от МНК, задача (2) не имеет аналитического решения и решается численно, но возможно приближение коэффициентов:

$$\hat{a} = \bar{y} - \hat{b}\bar{x},$$

$$\hat{b} = r_{xy} \frac{\sqrt{D_y}}{\sqrt{D_x}},$$

где r_{xy} - коэффициент корреляции Пирсона, $\sqrt{D_y}, \sqrt{D_x}$ - стандартные отклонения.

Робастная замена (для повышения устойчивости к выбросам):

$$\hat{b} = r_Q \frac{q_y^*}{q_x^*}$$

$$\hat{a} = \text{med}(y) - \hat{b} \text{med}(x),$$

где $med(y)$, $med(x)$ - выборочные медианы, q_x^* , q_y^* - нормированные интерквартильные широты, r_Q - квадрантный коэффициент корреляции.

МНМ устойчив к выбросам, так как использует модуль, а не квадрат отклонения. Робастная замена дополнительно повышает устойчивость за счёт использования медиан, интерквартильных широт и знакового коэффициента корреляции.

2.4 Погрешности

Абсолютная погрешность: $\Delta = |z - \hat{z}|$

Относительная погрешность $\delta = \frac{|z - \hat{z}|}{z} * 100\%$

где z - точное значение, $\hat{z}$ - приближённое значение

3. Реализация

Язык программирования: Python 3.14

Среда разработки: Jupyter Notebook

Библиотеки:

- numpy - для генерации данных и вычислений,
- matplotlib.pyplot - для построения графиков,
- scipy.optimize.minimize - для численной оптимизации МНМ

Краткое описание методов:

- `generate_data(n, a_true, b_true, seed)` — генерирует значения x_i равномерно на отрезке $[-1.8; 2]$ с шагом 0.2 (20 точек) и вычисляет $y_i = a + bx_i + \varepsilon_i$, где $\varepsilon_i \sim N(0,1)$.
- `add_outliers(y)` — добавляет выбросы: $y_1 \leftarrow y_1 + 10, y_{20} \leftarrow y_{20} - 10$.
- `mnk_fit(x, y)` — вычисляет МНК-оценки коэффициентов регрессии с помощью `np.polyfit(x, y, 1)`.
- `mnmm_objective(params, x, y)` — целевая функция для МНМ: сумма абсолютных отклонений. Минимизируется с помощью `scipy.optimize.minimize`.
- `mnmm_fit(x, y)` — вычисляет МНМ-оценки: начальное приближение берётся из МНК, затем выполняется численная оптимизация.
- `calculate_errors(a_est, b_est)` — вычисляет абсолютную и относительную погрешности.
- `print_table(...)` — выводит отформатированную таблицу с результатами.
- `plot_regression(...)` — строит график исходных данных, истинной прямой и прямых, полученных МНК и МНМ. При наличии выбросов выделяет их красными крестиками.

4. Результаты

Таблица 1: Результаты для выборки без выбросов

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	1.962	0.038	1.89	2.165	0.165	8.23
МНМ	2.232	0.232	11.58	2.100	0.100	4.98




Рисунок 1: Регрессия для выборки без выбросов

На рисунке 1 представлены исходные данные (чёрные точки), истинная регрессионная прямая (зелёная пунктирная), а также прямые, построенные по МНК (красная) и МНМ (синяя). Для чистых данных оба метода дают близкие к истинной прямой результаты.

Таблица 2: Результаты для выборки с выбросами

Метод	a	Δa	$\delta a, \%$	b	Δb	$\delta b, \%$
МНК	2.105	0.105	5.25	0.736	1.264	63.20
МНМ	2.332	0.332	16.61	2.000	0.000	0.01




Рисунок 2: Регрессия для выборки с выбросами

На рисунке 2 исходные данные содержат два выброса (отмечены красными крестиками). Видно, что прямая МНК сильно отклонилась от истинной (наклон b упал до 0.736), в то время как прямая МНМ осталась практически неизменной ($b = 2.000$), что демонстрирует устойчивость метода наименьших модулей к выбросам.

5. Обсуждение

В ходе выполнения лабораторной работы были построены линейные регрессионные модели для данных без выбросов и с выбросами. Оценка параметров проводилась двумя методами: методом наименьших квадратов (МНК) и методом наименьших модулей (МНМ).

Анализ результатов для выборки без выбросов:

Для данных, сгенерированных в соответствии с моделью $y = 2 + 2x + \varepsilon$, оба метода показали хорошие результаты. МНК дал оценки $a=1.962$ (относительная погрешность 1.89%) и $b=2.165$ (погрешность 8.23%). МНМ показал $a=2.232$ (погрешность 11.58%) и $b=2.100$ (погрешность 4.98%). Оба метода дали результаты, близкие к истинным значениям, при этом МНК оказался несколько точнее для параметра a , а МНМ — для параметра b . На графике (рисунок 1) видно, что обе регрессионные прямые близки к истинной.

Анализ результатов для выборки с выбросами:

После добавления выбросов ($y_1 + 10$ и $y_{20} - 10$) ситуация существенно изменилась:

- МНК продемонстрировал высокую чувствительность к выбросам. Оценка коэффициента наклона b упала до 0.736, а относительная погрешность составила 63.20%. Это объясняется тем, что МНК минимизирует сумму квадратов остатков, и выбросы, имея большие отклонения, сильно влияют на результат.
- МНМ оказался устойчивым к выбросам. Оценка коэффициента наклона $b=2.000$ практически совпала с истинным значением (относительная погрешность 0.01%). Это связано с тем, что МНМ минимизирует сумму модулей остатков, и влияние экстремальных значений значительно ослаблено.

На графике (рисунок 2) хорошо видно, что прямая МНК сильно отклонилась от истинной, практически "притянувшись" к выбросам. Прямая МНМ, напротив, сохранила правильный наклон и прошла через основное облако точек.

6. Выводы

По результатам лабораторной работы можно сделать следующие выводы:

- Метод наименьших квадратов (МНК) хорошо работает на данных без выбросов, давая точные оценки параметров регрессии. Однако он крайне чувствителен к аномальным значениям: даже два выброса способны существенно исказить результат (ошибка коэффициента b достигла 63.2%).
- Метод наименьших модулей (МНМ) демонстрирует высокую устойчивость (робастность) к выбросам. При добавлении двух выбросов оценка коэффициента b практически не изменилась (ошибка 0.01%), что подтверждает эффективность использования модуля вместо квадрата в целевой функции.
- На графиках наглядно видно, как прямая МНК "притягивается" к выбросам, в то время как прямая МНМ сохраняет правильную ориентацию и проходит через основную массу точек.
- При анализе данных, в которых возможно наличие выбросов, следует использовать робастные методы (например, МНМ). Для данных с нормальным распределением ошибок и без аномалий МНК может быть предпочтительнее из-за большей точности.

7. Приложение

Ссылка на репозиторий GitHub с исходным кодом программ, разработанных в ходе выполнения работ:

<https://github.com/KiselevaKsu/MathStatistics/tree/Lab6>